PREGLED I ANALIZA PODATAKA PROIZVODA SEPHORE

Jovana Nedeljković, IN32-2019

Anđelija Stančić, IN19-2019

OPIS SKUPA PODATAKA

- https://www.kaggle.com/datasets/nadyinky/sephora-products-and-skincare-reviews
- Ovaj skup podataka je prikupljen preko Python scraper-a u martu 2023.
- Sadrži:
- informacije o svim kozmetičkim proizvodima iz Sephora online prodavnice (preko 8.000), uključujući nazive proizvoda i brendova, cene, sastojke, ocene i sve karakteristike
- korisničke recenzije (preko 1 milion na preko 2.000 proizvoda) svih proizvoda uključujući i izglede korisnika i njihove ocene

- product_id jedinstveni identifikator proizvoda u Sephor
- product_name naziv proizvoda
- brand_id jedinstveni identifikator Brenda u Sephori
- brand_name naziv brenda
- loves_count broj ljudi koji su proizvod stavili u favorite
- rating prosečna ocena proizvoda
- reviews broj ljudi koji su ostavili komentar na proizvod
- ingredients sastojci proizvoda
- price_usd cena proizvoda
- limited_edition da li je proizvod limitirane serije
- new da li je proizvod nov
- online_only da li se prodaje samo online
- highlights lista tagova koji opisuju proizvod
- primary_category primarna kategorija proizvoda
- secondary_category sekundarna kategorija proizvoda
- tertiary_category tercijalna kategorija proizvoda

SEMANTIKA KOLONA – PODACI O PROIZVODIMA

- rating ocena koju je korisnik ostavio za dati proizvod
- is_recommended da li korisnik preporučuje dati proizvod
- total_neg_feedback_count broj negativnih komentara
- total_pos_feedback_count broj pozitivnih komenatara
- submission_time vreme ostavljanja komentara
- review_text komentar
- skin_tone boja kože korisnika koji je ostavio komentar
- eye_color boja očiju osobe koja je ostavila komentar
- skin_type tip kože korisnika koji je ostavio komentar
- hair_color boja kose korisnika koji je ostavio komentar
- product_id-id proizvoda za koji je ostavljen komentar

SEMANTIKA KOLONA – PODACI O FEEDBACK-U

Product

Key	Value	Туре
✓ (5) {_id : P473658}	{ 16 fields }	Document
"_" _id	P473658	String
"_" brand_id	6342	String
"_" brand_name	19-69	String
> [] highlights	[3 elements]	Array
> [] ingredients	[12 elements]	Array
iii limited_edition	0	Int32
in loves_count	2691	Int32
iii new	0	Int32
online_only	1	Int32
123 price_usd	195.0	Double
primary_category	Fragrance	String
"_" product_name	Purple Haze Eau de Parfum	String
"_" rating	3.2308	String
"_" reviews	13	String
"_" secondary_category	Women	String
"_" tertiary_category	Perfume	String


Feedback

Key	Value	Туре
✓ () (17) {_id: 33602438124}	{ 12 fields }	Document
"_" _id	33602438124	String
i32 rating	5	Int32
"_" is_recommended	1.0	String
ill total_neg_feedback_count	0	Int32
ill total_pos_feedback_count	0	Int32
11 submission_time	2023-03-16T00:00:00.000Z	Date
"_" review_text	i love how hydrating this makes my lips feel! perfect for an overnight lip mask or ju	String
"_" skin_tone	lightMedium	String
"_" eye_color	brown	String
"_" skin_type	combination	String
"_" hair_color	brown	String
"_" product_id	P420652	String

• Za svaki proizvod koji ima recenziju prikazati prosečnu ocenu, minimalnu ocenu i maksimalnu ocenu koju je dobio,broj pozitivnih i negativnih recenizija i koliko je puta bio preporučen od strane korisnika

```
Documents 1 to 50
                                                                                              Query Code P Explain Query JSON View ✓ Q Customize view ▼
1 \{
        "_id": "P429662",
        "min rating" : NumberInt(1),
        "max rating" : NumberInt(5),
        "product name" : "pores no more Vacuum Cleaner Pore Purifying Mask",
        "brand name" : "Dr. Brandt Skincare",
        "recommendation count": 87.0,
        "total neg feedback count" : NumberInt(209),
        "total pos feedback count" : NumberInt(771),
10
        "average rating" : 3.86
11 }
12 ▼{
13
        " id": "P448710",
14
        "min_rating" : NumberInt(1),
15
        "max rating" : NumberInt(5),
        "product name" : "pores no more Pore Purifying Cleanser",
16
17
        "brand name" : "Dr. Brandt Skincare",
18
        "recommendation count": 30.0,
19
        "total_neg_feedback_count" : NumberInt(71),
20
        "total pos feedback count" : NumberInt(225),
21
        "average rating": 4.31
22 }
23 ▼{
        " id" : "P429661",
24
        "min rating" : NumberInt(1),
25
26
        "max rating" : NumberInt(5),
        "product name": "pores no more Mattifying Hydrator Pore Minimizing Gel",
27
                                                                                                                      # Count Documents (1) 00:00:59.559
  1 document selected
```

 Za svaki brend čiji proizvodi imaju recenzije, izračunati koliko preporuka ukupno imaju njegovi proizvodi, i ukupan broj pozitivnih i negativnih recenzija za sve njegove proizvode



 Za svaki brend koji ima recenzije svojih proizvoda pronaći profil osobe koja najčešće predlaže njegove proizvode

```
Documents 1 to 50
        "brand_name" : "Algenist",
        "profiles" : [
               "skin_tone" : "light",
               "skin type" : "combination",
               "hair color" : "brown",
               "positive reviews": 190.0
10
11
12 ▼{
13
        "brand name" : "Alpha-H",
14 ▼
        "profiles" : [
15 ▼
               "skin tone" : "lightMedium",
               "skin_type" : "combination",
               "hair_color" : "brown",
19
               "positive_reviews": 29.0
20
21
22
23 ▼{
        "brand_name" : "Anastasia Beverly Hills",
25 ▼
        "profiles" : [
26 ▼
               "skin tone" : "fair",
                                                                                                           # Count Documents (1) 00:00:41.060
  1 document selected
```

 Pronaći najbolji proizvod za svaki brend na osnovu prosečne ocene i ukupnog broja preporuka korisnika u recenzijama

```
V Documents 1 to 50
                                                                                      1 ₹{
        "topProduct" : {
            "productId" : "P500716",
           "productName": "10 Day Results Kit",
           "primaryCategory" : "Skincare",
           "secondaryCategory" : "Value & Gift Sets",
           "tertiaryCategory": "",
           "avgRating" : 5.0,
           "totalRecommendations" : 5.0
9
10
        "brandName" : "Algenist"
11
12 }
13 ₹{
14 ▼
        "topProduct" : {
15
           "productId" : "P442537",
            "productName" : "Liquid Gold Firming Eye Cream",
16
17
           "primaryCategory" : "Skincare",
           "secondaryCategory" : "Eye Care",
18
19
           "tertiaryCategory": "Eye Creams & Treatments",
20
           "avgRating" : 5.0,
21
           "totalRecommendations": 9.0
22
        "brandName" : "Alpha-H"
23
24
25 ₹{
26 ▼
        "topProduct" : {
27
           "productId" : "P449150",
  1 document selected
                                                                                                             # Count Documents (1) 00:00:48.591
```

 Za svaki tip kože korisnika u bazi (dry, combination, sensetive, normal) pronaći po 2 proizvoda koja spadaju u "Moisturizers" kategoriju (tertiary_category) a koja su ljudi sa tim tipom kože najviše preporučivali u recenzijama

```
Raw shell output | Aggregate Query (line 3) * | Aggregate Query (line 59) * | Aggregate Query (line 103) * | Aggregate Query (line 166) * | Aggregate Query (line 239) * |
                        ∨ Documents 1 to 5
                                                                                             " id" : "dry",
        "products" : [
                 "product id" : "P394639",
                "product name": "The True Cream Aqua Bomb",
                "brand name" : "belif",
                "count": 807.0
10 🔻
11
                "product id" : "P427421",
12
                "product name": "Protini Polypeptide Firming Refillable Moisturizer",
13
                "brand name" : "Drunk Elephant",
14
                "count": 726.0
15
16
17 }
18 ▼{
         " id" : "oily",
19
20 ▼
         "products" : [
21 🔻
                "product id": "P394639",
23
                "product_name" : "The True Cream Aqua Bomb",
                "brand name" : "belif",
25
                "count": 641.0
26
27 ▼
                                                                                                                    # Count Documents 0 00:00:44.363
   1 document selected
```

• Za svoju boje kose, boju očiju i tip kože naći proizvode sa maksimalnom vrednošću broja korisnika koji su za te proizvode, iz tih kategorija, u toj kombinaciji, ostavili recenzije.

```
"max count" : 6319.0,
    "brand id" : "1254",
    "hair color" : "",
    "skin type" : "",
    "eve color" : ""
    "max count" : 5735.0,
    "brand id" : "1254",
   "hair color" : "",
    "skin type" : "combination",
    "eye color" : ""
    "max count" : 2892.0,
    "brand id" : "6234",
   "hair_color" : "brown",
                                                                                                                                Activate Windows
    "skin type": "combination",
    "eye color" : "brown"
                                                                                                                                     # Count Documents 00:02:51.778
document selected
```

Nalaženje prosečne ocene iz svih feedback-ova za 2022-u godinu, proizvoda koji su preporučeni i nalaze se u
trećoj kategoriji i njihovih brand-ova.

```
"brands" : [
           "brandId" : "6329",
           "brandName" : "FaceGym",
           "avgRating": 4.785714285714286
           "brandId" : "3902",
           "brandName": "SEPHORA COLLECTION",
           "avgRating" : 4.75
           "brandId" : "6482",
           "brandName" : "CANOPY",
           "avgRating": 4.891304347826087
           "brandId" : "6001",
           "brandName" : "NuFACE",
           "avgRating" : 5.0
                                                                                                                               Activate Windows
           "brandId": "6358".
                                                                                                                                     # Count Documents (1) 00:00:27.35
:ument selected
```

 Nalaženje profila svake osobe (boja kože, tip kože, boja očiju) koja je ostavila maksimalan broj pozitivnih feedback-ova za svaki produkt i svaki brand iz svih kategorija

```
"products" : [
            "product_id" : "P385320",
            "brands" : [
                    "brand name" : "NuFACE",
                    "profiles" : {
                        "skin type" : "oily",
                        "eye color" : "",
                        "hair_color" : "",
                        "total pos feedback count" : NumberInt(298)
            "product_id": "P389097",
            "brands" : [
                    "brand name" : "HUM Nutrition",
                    "profiles" : {
                        "skin type" : "oily",
                        "eye_color" : "",
                        "hair_color" : "",
                        "total pos feedback count" : NumberInt(23)
                                                                                                                                 Activate Windows
                                                                                                                                       # Count Documents 00:11:01.661
document selected
```

 Nalaženje brenda sa najjeftinijim proizvodima i broj pozitivnih feedback-ova iz tercijalne kategorije za tipove i boje kože

```
"min price" : 3.0,
    "brands" : [
        "SEPHORA COLLECTION",
        "BeautyBio",
        "Koh Gen Do"
    "tertiary_category" : "Face Wipes",
    "skin tone": "light",
    "skin type" : "dry"
    "min_price" : 3.0,
    "brands" : [
        "Koh Gen Do",
        "BeautyBio",
        "Shiseido",
        "SEPHORA COLLECTION"
    "tertiary_category" : "Face Wipes",
    "skin tone": "lightMedium",
    "skin_type" : "oily"
    "min_price" : 3.0,
    "brands" : [
                                                                                                                                Activate Windows
        "SEPHORA COLLECTION",
        "Koh Gen Do",
                                                                                                                                      # Count Documents 0:00:05:22.789
cument selected
```

• Nalaženje proizvoda iz svih kategorija sa maksimalnom cenom za svaku ocenu

```
"rating": "3.0417",
     "brand" : "tarte",
     "product" : {
          " id": "P457468",
         "brand_id" : "5648",
         "brand name" : "tarte",
         "highlights" : [
          "ingredients" : [
              "['Water/Aqua/Eau",
             " Propylene Glycol",
              " Dihydroxyacetone",
             " PEG-6 Caprylic/Capric Glycerides",
             " Dihydroxypropyl PEG-5 Linoleammonium Chloride",
             " PEG-7 Glyceryl Cocoate",
             " Sodium Lauroyl Sarcosinate",
             " Hamamelis Virginiana (Witch Hazel) Bark/Leaf/Twig Extract",
             " Phenoxyethanol",
             " Caprylyl Glycol",
             " Potassium Sorbate",
             " Hexylene Glycol",
              " Ethoxydiglycol",
                                                                                                                                 Activate Windows
             " Erythrulose",
             " Glycerin"
                                                                                                                                       # Count Documents 00:03:02.711
document selected
```

```
db.product_with_feedbacks.createIndex({ "brand_name": 1 });
db.product_with_feedbacks.createIndex({ "_id": 1 });
db.product_with_feedbacks.createIndex({ "feedback.rating": 1 });
db.product_with_feedbacks.createIndex({ "tertiary_category": 1 });
```

Transformacija baze

Product with feedback

Key	Value	Туре
✓ () (17) {_id: 33602438124}	{ 12 fields }	Document
"_" _id	33602438124	String
332 rating	5	Int32
"_" is_recommended	1.0	String
iii total_neg_feedback_count	0	Int32
iii total_pos_feedback_count	0	Int32
🗊 submission_time	2023-03-16T00:00:00.000Z	Date
"_" review_text	i love how hydrating this makes my lips feel! perfect for an overnight lip mask or ju	String
"_" skin_tone	lightMedium	String
"_" eye_color	brown	String
"_" skin_type	combination	String
"_" hair_color	brown	String
"_" product_id	P420652	String

• Za svaki proizvod koji ima recenziju prikazati prosečnu ocenu, minimalnu ocenu i maksimalnu ocenu koju je dobio,broj pozitivnih i negativnih recenizija i koliko je puta bio preporučen od strane korisnika

```
∨ Documents 1 to 50
                                                                                       1 ₹{
        " id" : "P429662",
        "product name": "pores no more Vacuum Cleaner Pore Purifying Mask",
        "primary category" : "Skincare",
        "min rating": 1.0.
        "max rating" : 5.0,
        "total neg feedback count" : NumberInt(209),
        "total pos feedback count" : NumberInt(771),
        "total is recommended": 87.0,
10
        "average_rating" : 3.86
11 }
12 ₹{
        " id": "P448710",
13
        "product_name" : "pores no more Pore Purifying Cleanser",
14
15
        "primary category" : "Skincare",
        "min rating": 1.0,
16
17
        "max_rating" : 5.0,
18
        "total neg feedback count" : NumberInt(71),
        "total pos feedback count" : NumberInt(225),
19
20
        "total is recommended" : 30.0,
21
        "average_rating": 4.31
22 }
23 ▼{
24
        " id": "P429661",
25
        "product_name": "pores no more Mattifying Hydrator Pore Minimizing Gel",
26
        "primary category": "Skincare",
        "min rating" : 1.0.
  1 document selected
                                                                                                              # Count Documents
```

• Za svaki brend čiji proizvodi imaju recenzije, izračunati koliko preporuka ukupno imaju njegovi proizvodi, i ukupan broj pozitivnih i negativnih recenzija za sve njegove proizvode

```
Documents 1 to 50
1 \{
        "recommendation count": 17719.0,
        "total neg feedback count" : NumberInt(14960),
        "total pos feedback count" : NumberInt(57644),
        "brand name" : "LANEIGE"
6 }
7 ₹{
        "recommendation count": 16876.0,
9
        "total neg feedback count" : NumberInt(58181),
10
        "total pos feedback count" : NumberInt(205793),
        "brand name" : "The Ordinary"
11
12 }
13 ▼{
14
        "recommendation count": 14638.0,
15
        "total neg feedback count" : NumberInt(26231),
16
        "total pos feedback count" : NumberInt(104591),
17
        "brand name" : "Drunk Elephant"
18 }
19 ▼{
20
        "recommendation count": 14185.0,
        "total neg feedback count" : NumberInt(18921),
21
22
        "total pos feedback count" : NumberInt(70904),
23
        "brand name" : "Tatcha"
24 }
                                                                                                               # Count Documents
                                                                                                                                ① 00:00:01.025
  1 document selected
```

• Za svaki brend koji ima recenzije svojih proizvoda pronaći profil osobe koja najčešće predlaže njegove proizvode

```
V Documents 1 to 50
                                                                                     1 \( \{ \)
        "brand_name" : "Algenist",
       "profiles" : [
              "skin tone" : "light",
              "skin type" : "combination",
              "hair color" : "brown",
               "positive reviews": 190.0
10
11
12 V {
13
        "brand name" : "Alpha-H",
14 V
       "profiles" : [
15 V
              "skin tone": "lightMedium",
              "skin type" : "combination",
              "hair color" : "brown",
19
               "positive reviews" : 29.0
20
21
22 }
        "brand_name" : "Anastasia Beverly Hills",
24
       "profiles" : [
25 ▼
26
               "skin tone" : "fair".
                                                                                                                           00:00:01.454
  1 document selected
                                                                                                           # Count Documents
```

 Pronaći najbolji proizvod za svaki brend na osnovu prosečne ocene i ukupnog broja preporuka korisnika u recenzijama

```
∨ Documents 1 to 50
1 \( \{ \)
        "topProduct" : {
            "productId": "P500716",
           "productName" : "10 Day Results Kit",
           "primaryCategory" : "Skincare",
           "secondaryCategory": "Value & Gift Sets",
           "tertiaryCategory" : "",
           "avgRating" : 5.0,
           "totalRecommendations" : 5.0
10
        "brandName" : "Algenist"
11
12
13 ▼{
        "topProduct" : {
14 ▼
           "productId": "P442537",
15
16
           "productName" : "Liquid Gold Firming Eye Cream",
17
           "primaryCategory" : "Skincare",
           "secondaryCategory" : "Eye Care",
           "tertiaryCategory": "Eye Creams & Treatments",
19
20
           "avgRating" : 5.0,
21
           "totalRecommendations": 9.0
22
        "brandName" : "Alpha-H"
23
24 }
25 1
                                                                                                              # Count Documents 00:00:01.271
  1 document selected
```

• Za svaki tip kože korisnika u bazi (dry, combination, sensetive, normal) pronaći po 2 proizvoda koja spadaju u "Moisturizers" kategoriju (tertiary_category) a koja su ljudi sa tim tipom kože najviše preporučivali u recenzijama

```
\leftarrow \leftarrow \rightarrow | 50
                              Documents 1 to 5
                                                                                                   Query Code P Explain Query JSON View ✓ C Customize view ▼
1 *{
         " id" : "normal",
         "products" : [
 4 v
                 "product id" : "P394639",
                 "product_name" : "The True Cream Aqua Bomb",
                 "brand name" : "belif",
                 "count": 628.0
9
10 V
11
                 "product_id" : "P427421",
12
                 "product name": "Protini Polypeptide Firming Refillable Moisturizer",
13
                 "brand name" : "Drunk Elephant",
14
                 "count": 482.0
15
16
17 }
18 ▼{
          " id" : "oily",
19
20 ▼
          "products" : [
21 ▼
22
                 "product id": "P394639",
23
                 "product_name" : "The True Cream Aqua Bomb",
                 "brand name" : "belif",
24
25
                 "count": 641.0
26
             },
27 ▼
    1 document selected
                                                                                                                            # Count Documents
                                                                                                                                              ① 00:00:00.263
```

• Za svoju boje kose, boju očiju i tip kože naći proizvode sa maksimalnom vrednošću broja korisnika koji su za te proizvode, iz tih kategorija, u toj kombinaciji, ostavili recenzije.

```
"max count" : 6319.0,
   "brand id" : "1254",
   "hair_color" : "",
   "skin_type" : "",
   "eye color" : ""
   "max count" : 5735.0,
   "brand_id" : "1254",
   "hair color" : "",
   "skin type" : "combination",
   "eye color" : ""
   "max count" : 2892.0,
   "brand id" : "6234",
   "hair_color" : "brown",
   "skin type" : "combination",
   "eye color" : "brown"
   "max_count" : 2430.0,
   "brand_id" : "6234",
                                                                                                                                 Activate Windows
   "hair_color" : "black",
   "skin type": "combination",
                                                                                                                                       # Count Documents 0:00:00:05.656
ocument selected
```

 Nalaženje prosečne ocene iz svih feedback-ova za 2022-u godinu, proizvoda koji su preporučeni i nalaze se u trećoj kategoriji i njihovih brand-ova.

```
"brands" : [
            "brandId" : "6309",
           "brandName" : "goop",
            "avgRating": 4.714285714285714
            "brandId" : "7017",
           "brandName": "iluminage",
            "avgRating": 4.8
           "brandId" : "5668",
           "brandName": "Dr. Dennis Gross Skincare",
            "avgRating": 4.742857142857143
            "brandId" : "6136",
           "brandName": "DERMAFLASH",
            "avgRating": 4.836601307189542
                                                                                                                              Activate Windows
            "brandId" : "6256",
            "brandName" • "Mount Lai"
                                                                                                                                    # Count Documents 00:00:03.034
cument selected
```

 Nalaženje profila svake osobe (boja kože, tip kože, boja očiju) koja je ostavila maksimalan broj pozitivnih feedback-ova za svaki produkt i svaki brand iz svih kategorija

```
"products" : [
           "product id": "P385320",
           "brands" : [
                   "brand name": "NuFACE",
                   "profiles" : {
                       "skin color" : "",
                       "skin type" : "oily",
                       "eye_color" : "",
                       "hair_color" : "",
                       "total pos feedback count" : NumberInt(298)
           "product_id": "P389097",
           "brands" : [
                    "brand name": "HUM Nutrition",
                   "profiles" : {
                       "skin color" : "",
                                                                                                                                Activate Windows
                       "skin type" : "oily",
                       "eye color" : "",
                                                                                                                                Go to Settings to activate Windows.
                                                                                                                                      # Count Documents 00:00:00:00.076
cument selected
```

 Nalaženje brenda sa najjeftinijim proizvodima i broj pozitivnih feedback-ova iz tercijalne kategorije za tipove i boje kože

```
"min price" : 3.0,
    "total_pos_feedback" : NumberInt(104),
    "brands" : [
        "BeautyBio",
        "Koh Gen Do",
        "SEPHORA COLLECTION"
    "tertiary_category" : "Face Wipes",
    "skin tone" : "light",
    "skin type" : "dry"
    "min price" : 3.0.
    "total pos feedback" : NumberInt(58),
    "brands" : [
        "SEPHORA COLLECTION",
       "Koh Gen Do",
        "BeautyBio",
        "Shiseido"
    "tertiary_category" : "Face Wipes",
    "skin_tone" : "lightMedium",
    "skin type" : "oily"
                                                                                                                                  Activate Windows
    "min price" : 3.0,
    "total_pos_feedback" : NumberInt(113),
                                                                                                                                        # Count Documents (1) 00:00:02.317
locument selected
```

• Nalaženje proizvoda iz svih kategorija sa maksimalnom cenom za svaku ocenu

```
"rating": "3.0417",
     "brand" : "tarte",
     "product" : {
         " id": "P457468",
         "brand_id" : "5648",
         "brand name" : "tarte",
         "highlights" : [
         "ingredients" : [
             "['Water/Aqua/Eau",
             " Propylene Glycol".
             " Dihydroxyacetone",
             " PEG-6 Caprylic/Capric Glycerides",
             " Dihydroxypropyl PEG-5 Linoleammonium Chloride",
             " PEG-7 Glyceryl Cocoate",
             " Sodium Lauroyl Sarcosinate",
             " Hamamelis Virginiana (Witch Hazel) Bark/Leaf/Twig Extract",
             " Phenoxyethanol",
             " Caprylyl Glycol",
             " Potassium Sorbate",
             " Hexylene Glycol",
                                                                                                                                 Activate Windows
             " Ethoxydiglycol",
             " Erythrulose",
                                                                                                                                       # Count Documents 00:00:39.794
ocument selected
```

Optimizovano vreme izvršavanja

